Introdução à Linguagem de Programação em R para tratamento de dados de poluição do ar

R básico e data frames

Mario Gavidia-Calderón, Rafaela Squizzato, Thiago Nogueira

05/02/2024

Universidade de São Paulo

Introdução

RStudio

Sintaxe Básica

Data Frames

Introdução

Por que o curso?

Efeitos adversos à saúde

Por que o curso?

Carga global de doenças da poluição do ar em 2015:

- 19 % de todas as mortes cardiovasculares.
- 23 % de toas as mortes por câncer de pulmão.

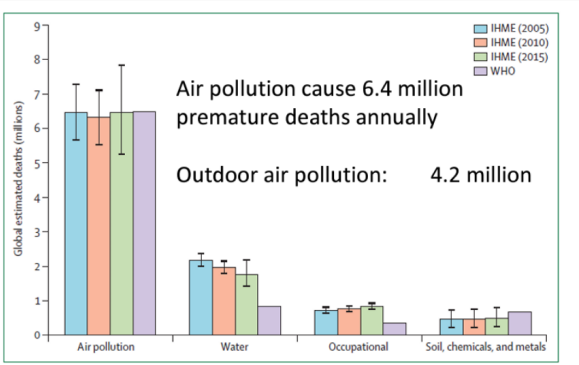

Figure 4: **Global estimated deaths (millions) by pollution risk factor, 2005–15**
Using data from the GBD study[42] and WHO.[39] IHME=Institute for Health Metrics and Evaluation.

Por que o curso?

Ranking global de fatores de risco por número total de mortes em 2019

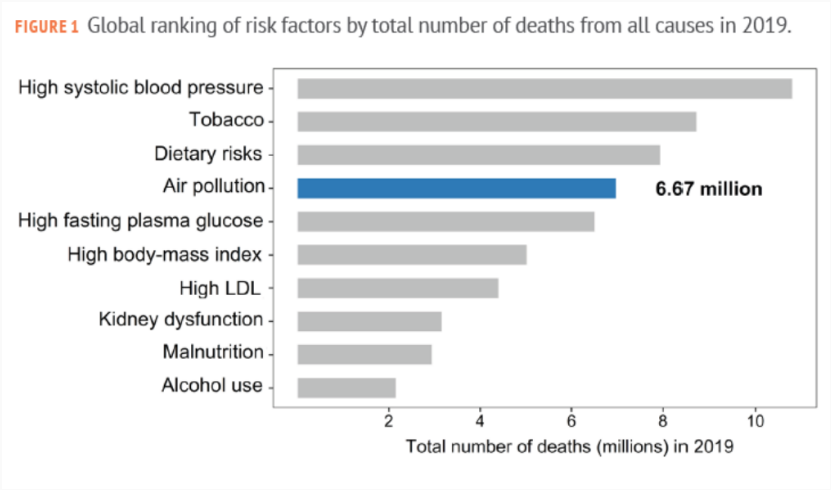

Por que o curso?

”Data! Data! Data!” He cried impatiently. ”I can’t make bricks without clay.”

Arthur Conan Doyle, The Adventure of the Copper Beeches- a Sherlock Holmes Short Story.

- Precisamos conhecer o nível da poluição.
- Para isso precisamos de medições: dados.
- Este curso tem como objetivo mostrar como trabalhar com dados de poluição do ar no R.

Por que o curso?

Além disso

- Analizadores de poluentes medem concentrações com maior frequência.
- R é uma ótima ferramenta para mexer com dados.
- É importante conhecer uma linguagem de programação.

Um questionário

Por que R?

- R é uma **Linguagem de programação** para a análise de dados.
  - Um sistema para **estatística**.
  - Um sistema de computação gráfica e **estatística**.
  - Um ambiente para a análise de dados e **estatística**.

Por que R?

- É *open source* (é **livre**).
- Funciona em qualquer **sistema operacional**.
- Podemos trabalhar **com muitos dados** e **tipos de dados**.
- Grande comunidade de usuários: **Muita ajuda on-line**.
- **Reprodutibilidade** das ciências.

Por que R?

- Muitos **pacotes** para muitas áreas das ciências.
  - `openair` → poluição do ar.
  - `sf` e `raster` → GIS.
  - `Rmarkdown` → Documentos e apresentações.
  - `shiny` → aplicações e *dashboards*.
  - etc, etc, etc

RStudio

RStudio

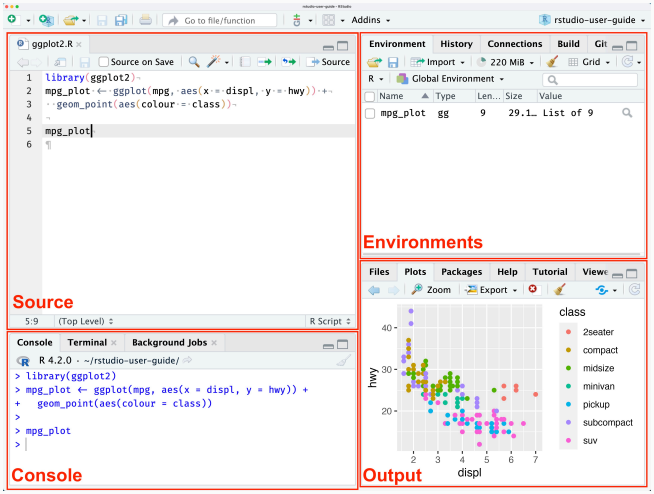

Figure 1: Distribuição das janelas do RStuido. Fonte: RStudio User Guide

RStudio

- É importante aprender os *keyboard shortcuts*.
  - `Ctrl + 1` : Janela scripts.
  - `Ctrl + 2` : Janela console.
  - `Alt + -` : `<-`
  - `Ctrl + d` : Apaga linha.
  - `TAB`: Autocompleta nome de funções e diretórios de arquivos.
- Na console, ↑ e ↓ procura comandos anteriores.

RStudio

- No scripts
  - `Alt + shift +` ↓: Copia linha.
  - `Ctrl + Enter`: Executa a linha.
  - `Ctrl + a`: Seleciona todo o script.

Sintaxe Básica

The theoretical minimum

- *What you need to know to start doing R*

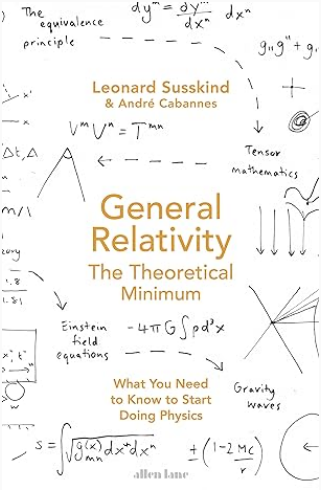

Antes de começar

Lei de Murphy

Se algo pode dar errado, dará.

- R é *case-sensitive*: `uma_variavel` $\neq$ `Uma_variavel`.
- Lembrem de fechar os `( )`
- Lembrem das `,`
- Atentos ao seguir os exemplos.

R como calculadora

- R é uma calculadora.
- Segue a ordem das operações

```
(5 + 10 * 2 / 4) ^ 2 - 5
```

```
## [1] 95
```

Declarar variavéis

- No R usamos <- em vez de = para definir variavéis.

```
R <- 8.314
R
```

```
## [1] 8.314
```

Comentar

- Para comentar usamos **#**. O código após o **#** não é lido.

```
R <- 8.314 # Constante universal dos gases (J K / mol)
R
```

```
## [1] 8.314
```

Funções

- Para usar funções: **nome_da_função()**.
- Dentro dos **()** colocamos os **argumentos**.

```
class(R)
```

```
## [1] "numeric"
```

Objetos

- No R existem diversos tipos de objetos.
- **character**

```
o3_nome <- "ozônio"
class(o3_nome)
```

```
## [1] "character"
```

- **numeric**

```
this_year <- 2024
g <- 9.81 # m/s2
class(this_year)
```

```
## [1] "numeric"
```

Objetos

- booleans

```
verdade <- TRUE
verdade
```

```
## [1] TRUE
```

```
falso <- 5 > 10
falso
```

```
## [1] FALSE
```

```
muito_falso <- "cinco" == "5"
muito_falso
```

Vetores

- É definido usando a função **c()**. Só podem ter um único tipo de objeto.

```
pontos_cardeais <- c("N", "E", "S", "W")
pontos_cardeais # só character
```

```
## [1] "N" "E" "S" "W"
```

```
pontos_cardeais_graus <- c(0, 90, 180, 270)
class(pontos_cardeais_graus) # só numeric
```

```
## [1] "numeric"
```

Vetores

- Uma sequência é definida **seq(início, final, intervalo)**

```
de_1ate5 <- seq(1, 5)
de_1ate5
```

```
## [1] 1 2 3 4 5
```

```
pares_ate10 <- seq(0, 10, 2)
pares_ate10
```

```
## [1]  0  2  4  6  8 10
```

```
sec_float <- seq(0, 1, 0.2)
sec_float
```

Vetores

- Para saber quantos elementos tem um vetor usamos a função `length`.

```
length(de_1ate5)
```

```
## [1] 5
```

```
length(sec_float)
```

```
## [1] 6
```

Vetores

- Para selecionar elementos do vetor: **nome_vetor[posição]**:

```
# Primeiro elemento
pontos_cardeais_graus[1]
```

```
## [1] 0
```

```
# Último elemento
pontos_cardeais_graus[4]
```

```
## [1] 270
```

Vetores

- Podemos selecionar vários elementos usando **outro vetor**

```
# Segundo y tercero
pontos_cardeais[c(2, 3)]
```

```
## [1] "E" "S"
```

- Podemos eliminar elementos usando **nome_vetor[-posição]**

```
GEE <- c("H2O", "CO2", "O2", "CH4")
GEE
```

```
## [1] "H2O" "CO2" "O2"  "CH4"
```

```
GEE[-3] # Oxigênio não é GEE
```

Vetores

- Podemos Substituir um elemento do vetor assim:

```
# Substituímos Oxigênio por Ozônio
GEE[3] <- "O3"
GEE
```

```
## [1] "H2O" "CO2" "O3"  "CH4"
```

Exercicio 1

Criar três vetores. Um vetor chamado `pol_sp` com os poluentes que tem padrão de qualidade do ar no Estado de São Paulo. Outro vetor chamado `pol_amostra` com **o menor tempo de amostragem** em horas. Finalmente, um vetor chamado `pol_pqa` com o respectivo padrão de qualidade do ar.

Referência: Padrões de qualidade do ar CETESB

Exercicio 1

```
pol_sp <- c("MP10", "MP2.5", "SO2", "NO2", "O3", "CO", "FMC", "PTS", "P
pol_amostra <- c(24, 24, 24, 1, 8, 8, 24, 24, 365*24)
pol_pqa <- c(100, 50, 40, 240, 130, 9, 100, 240, 0.5)
```

Operações *Element-wise*

```
tempC <- c(27, 32, 28, 26)
tempK <- tempC + 273.15
tempK
```

```
## [1] 300.15 305.15 301.15 299.15
```

```
tempk_chr <- as.character(tempK)
str(tempk_chr)
```

```
##  chr [1:4] "300.15" "305.15" "301.15" "299.15"
```

Operações *Element-wise*

```
pol_atr <- c("nome", "pm", "conc", "unit")
paste("o3", pol_atr, sep = "_")
```

```
## [1] "o3_nome" "o3_pm"   "o3_conc" "o3_unit"
```

Data Frames

R: Objetos - `data frames`

- Um `data frame` é uma **tabela**
- Uma matriz **indexada**: tem nomes das **colunas** e **linhas**.
- Cada **coluna** é uma **variável**.
- Cada **linha** é uma **observação**.
- Um conjunto de vetores.

data frame

- Criamos um **data frame** usando a função **data.frame()**

```
gases <- c("N2", "O2", "Ar", "CO2")
massa_molar <- c(28, 32, 40, 12 + 2 * 16)
percentagem <- c(78.08, 20.95, 0.9, 0.04)

ar <- data.frame(gas = gases,
                 W = massa_molar,
                 per = percentagem)
```

data frame

```
ar
```

```
##   gas  W   per
## 1  N2 28 78.08
## 2  O2 32 20.95
## 3  Ar 40  0.90
## 4 CO2 44  0.04
```

data frame

- Criamos um **data frame** usando a função **data.frame()**

```
ar <- data.frame(gas = c("N2", "O2", "Ar", "CO2"), # Ou diretamente
                 W = c(28, 32, 40, 12 + 2 * 16),
                 per = c(78.08, 20.95, 0.9, 0.04))
```

data frame

```
ar
```

```
##   gas  W   per
## 1  N2 28 78.08
## 2  O2 32 20.95
## 3  Ar 40  0.90
## 4 CO2 44  0.04
```

Selecionar colunas $

- Selecionamos uma **coluna** de um **`data frame`** como um **vetor**
- Sintaxis: `df$nome_coluna`
- E.g. Nome dos componentes do ar

```
ar$gas
```

```
## [1] "N2"  "O2"  "Ar"  "CO2"
```

```
class(ar$gas)
```

```
## [1] "character"
```

Selecionar filas e colunas [ ]

- Selecionamos uma **coluna** de um **`data frame`** como um **`data frame`**
- Sintaxis: `df[interiro]` ou `df[nome_coluna]`
- E.g. Nome dos componentes do ar

```
ar[1] # ou ar[”gas”]
```

```
##   gas
## 1  N2
## 2  O2
## 3  Ar
## 4 CO2
```

```
class(ar[1])
```

Selecionar filas e colunas [ ]

- Algumas funções precisam **vetores** como **input**
- e.g. média massa molar

```
mean(ar["W"])
```

```
## Warning in mean.default(ar["W"]): argument is not numeric or logical
## NA
```

```
## [1] NA
```

```
mean(ar$W)
```

```
## [1] 36
```

Criando novas colunas

- Usamos $: **df$nova_coluna <- nova_coluna**

```
# Adicionamos o nome completo dos gases.
ar$name <- c("Nitrogênio",
             "Oxigênio",
             "Argônio",
             "Diôxido de Carbono")
ar
```

```
##   gas  W   per               name
## 1  N2 28 78.08         Nitrogênio
## 2  O2 32 20.95           Oxigênio
## 3  Ar 40  0.90            Argônio
## 4 CO2 44  0.04 Diôxido de Carbono
```

Algumas funções importantes

- Número de linhas: **`nrow()`**
- Número de colunas: **`ncol()`**

```
nrow(ar)
```

```
## [1] 4
```

```
ncol(ar)
```

```
## [1] 4
```

Algumas funções importantes

- Tipo de objeto de cada coluna: **str()**

```
str(ar)
```

```
## 'data.frame':    4 obs. of  4 variables:
##  $ gas : chr  "N2" "O2" "Ar" "CO2"
##  $ W   : num  28 32 40 44
##  $ per : num  78.08 20.95 0.9 0.04
##  $ name: chr  "Nitrogênio" "Oxigênio" "Argônio" "Diôxido de Carbono"
```

- nome das colunas

```
names(ar)
```

```
## [1] "gas"  "W"    "per"  "name"
```

Algumas funções importantes

- Primeiras observações: **head()**
- Últimas observações: **tail()**

```
head(ar)
```

```
##   gas  W   per               name
## 1  N2 28 78.08         Nitrogênio
## 2  O2 32 20.95           Oxigênio
## 3  Ar 40  0.90            Argônio
## 4 CO2 44  0.04 Diôxido de Carbono
```

```
tail(ar)
```

```
##   gas  W   per               name
```

Algumas funções importantes

- Primeiras observações: **head()**
- Últimas observações: **tail()**

```
head(ar, 2)
```

```
##   gas  W   per       name
## 1  N2 28 78.08 Nitrogênio
## 2  O2 32 20.95   Oxigênio
```

```
tail(ar, 2)
```

```
##   gas  W  per               name
## 3  Ar 40 0.90            Argônio
## 4 CO2 44 0.04 Diôxido de Carbono
```

Substituição de coluna

- Para subsituir uma coluna, ela tem que ter o mesmo número de filas.

```
# Em espanhol
ar$nombres <- c("Nitrógeno",
                "Oxígeno",
                "Argón",
                "Dióxido de carbono")
ar
```

```
##   gas  W   per               name           nombres
## 1  N2 28 78.08         Nitrogênio          Nitrógeno
## 2  O2 32 20.95           Oxigênio            Oxígeno
## 3  Ar 40  0.90            Argônio              Argón
## 4 CO2 44  0.04 Diôxido de Carbono Dióxido de carbono
```

Exercicio 2

- Criar um `data.frame` llamado `pqa_sp` usando os vetores do Exercicio 1.
- Adiciona una coluna chamada `pm` con o peso molecular de cada poluente. Para MP colocar 1.
- Adiciona una coluna chamada `nome` com o nome completo de cada poluente.

Exercicio 2

```
pqa_sp <- data.frame(
  pol_sp,
  pol_amostra,
  pol_pqa
)
pqa_sp$pm <- c(1, 1, 32 + 16 * 2, 14 + 16 * 2, 16 * 3, 12 + 16, 1, 1, 2
```

`data frames`: Ler arquivos `.csv`

- Vamos ler dados do ano 2023 do aeroporto de Guarulhos.
- Os dados são baixados do site **ASOS Network da Iowa State University**.
- No R para ler tabelas em csv (e para outros formatos) usamos a função ‘read.table()‘.
- Esta função precisa saber o **diretório do arquivo**. Para isso podemos usar a função **`file.choose()`**.

data frames Ler arquivos .csv

```
gru <- read.table("../../data/SBGR.csv", # ou file.choose()
                  header = TRUE, # se as colunas tem nome
                  sep = ",", # o separador de colunas
                  dec = ".") # o separador decimal
```

- Exploramos o nome das colunas do data frame:

```
names(gru)
```

```
##  [1] "station"           "valid"             "tmpf"
##  [4] "dwpf"              "relh"              "drct"
##  [7] "sknt"              "p01i"              "alti"
## [10] "mslp"              "vsby"              "gust"
## [13] "skyc1"             "skyc2"             "skyc3"
## [16] "skyc4"             "skyl1"             "skyl2"
## [19] "skyl3"             "skyl4"             "wxcodes"
## [22] "ice_accretion_1hr" "ice_accretion_3hr" "ice_accretion_6hr"
## [25] "peak_wind_gust"    "peak_wind_drct"    "peak_wind_time"
## [28] "feel"              "metar"             "snowdepth"
```

- Exploramos a estrutura do `data frame`.

```
str(gru)
```

```
## 'data.frame':    8736 obs. of  30 variables:
##  $ station          : chr  "SBGR" "SBGR" "SBGR" "SBGR" ...
##  $ valid            : chr  "2023-01-01 00:00" "2023-01-01 01:00" "20
##  $ tmpf             : num  69.8 68 69.8 68 66.2 64.4 64.4 64.4 62.6
##  $ dwpf             : num  66.2 66.2 68 66.2 66.2 64.4 64.4 64.4 62.
##  $ relh             : num  88.3 94 94 94 100 ...
##  $ drct             : num  80 110 80 70 60 80 80 100 0 0 ...
##  $ sknt             : num  3 5 6 6 6 7 4 3 0 0 ...
##  $ p01i             : num  0 0 0 0 0 0 0 0 0 0 ...
##  $ alti             : num  30.1 30.1 30.1 30.1 30.1
```

Operações

- A temperatura está em Farenheit e a velocidade de vento está em nós.

```
gru$tc <- (gru$tmpf - 32) * 5 / 9
```

Operações

- A temperatura está em Farenheit e a velocidade de vento está em nós.

```
gru$ws <- gru$sknt * 0.51
```

Análise exploratória de dados (AED)

- Vamos olhar as estatísticas básicas usando `summary()` da temperatura, velocidade do vento, umidade do ar.

```
summary(gru[c("tc", "relh", "ws")])
```

```
##        tc              relh              ws
##  Min.   : 7.00   Min.   : 18.33   Min.   : 0.000
##  1st Qu.:17.00   1st Qu.: 65.54   1st Qu.: 1.530
##  Median :20.00   Median : 83.09   Median : 2.550
##  Mean   :20.71   Mean   : 78.27   Mean   : 2.763
##  3rd Qu.:24.00   3rd Qu.: 93.79   3rd Qu.: 3.570
##  Max.   :37.00   Max.   :100.00   Max.   :11.730
```

- Ou podemos calcular *manualmente*:

```
mean(gru$tc, na.rm = TRUE) # na.rm = TRUE não considera NA
```

```
## [1] 20.71028
```

```
median(gru$tc, na.rm = TRUE)
```

```
## [1] 20
```

Análise exploratória de dados (AED)

```r
max(gru$tc, na.rm = TRUE)
```

```
## [1] 37
```

```r
min(gru$tc, na.rm = TRUE)
```

```
## [1] 7
```

```r
sd(gru$tc, na.rm = TRUE)
```

```
## [1] 4.903718
```

Exercio 3

- Baixe os dados do aeroporto de campo de marte para o ano 2023.
- Transforme a Temperatura para Celcius, e a velocidade do vento para m s^{-1}.
- Existen datos faltantes?
- Todos as colunas foram lidas corretamente?

Um plot simples

```
plot(gru$tc, # vetor para plotar
     t = "l", # tipo de plot, l = linha
     xlab = "2023", # nome do eixo x
     ylab = "Temperatura (C)", # nome eixo y
     col = "orange", # color da linha
     lwd = 1.25 # largura linha
     )
```

Um plot simples

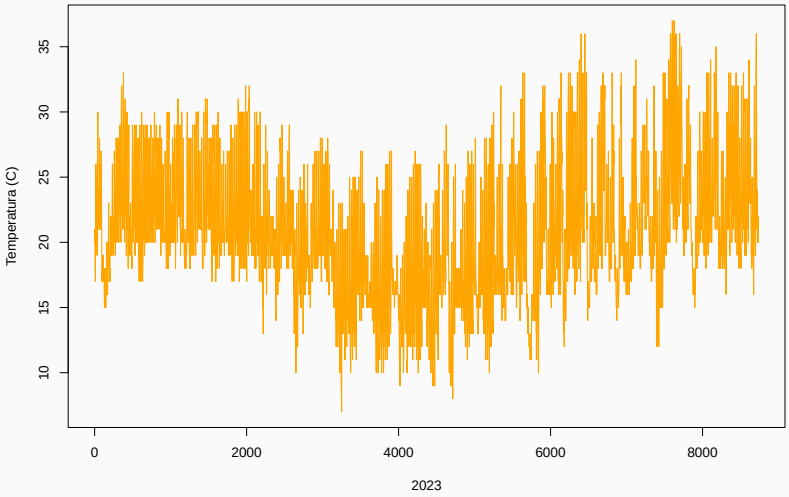

Histograma

```
hist(gru$tc)
```

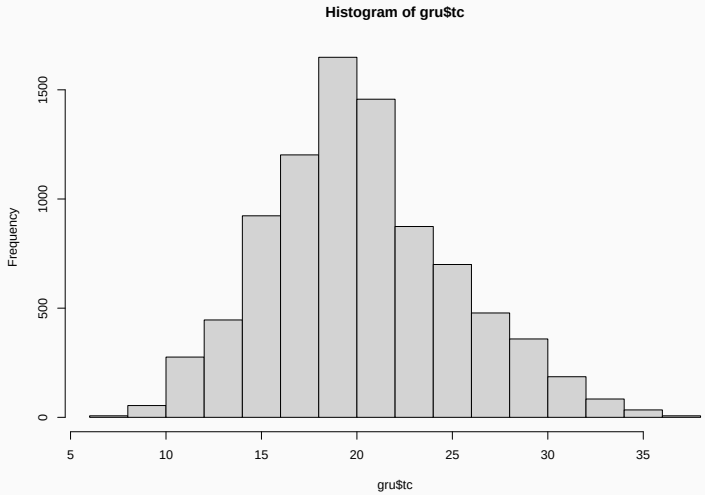

Um diagrama de caixa

```
boxplot(gru$tc)
```

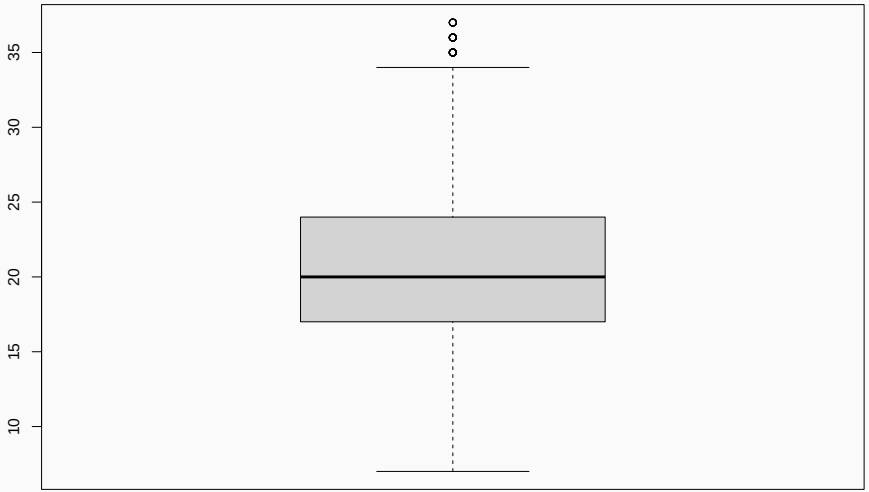

Um *scatter plot*

```
plot(gru$tc, # valores eixo x
     gru$relh, # valores eixo y
     col = "lightblue", # color dos pontos
     xlab = "Temperatura (C)", # nome eixo x
     ylab = "Umidade relativa (%)" # nome eixo y
     )
```

Um *scatter plot*

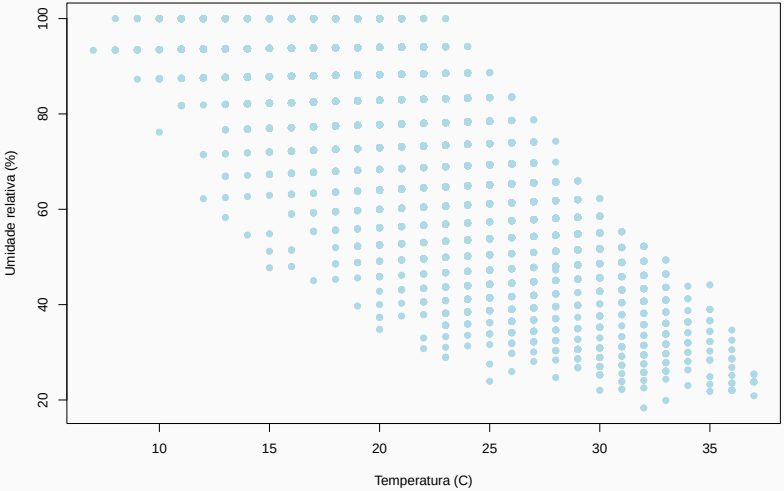

Coeficiente de correlação

```
cor(gru$tc, # variavel x
    gru$relh) # variavel y
```

```
## [1] -0.7436237
```

Exercicio 4

- Calcule a média, mediana, min, max e sd, da Temperatura, Umidade relativa, Velocidade do vento no Aeroporto Campo de Marte.
- Faça uma série temporal, um histograma e um boxplot destes parâmetros.