

Introdução à Linguagem de Programação em R para tratamento de dados de poluição do ar

Mario Gavidia-Calderón, Rafaela Squizzato, Thiago Nogueira

06/02/2024

Universidade de São Paulo

Pacotes

Do Excel para R

Subset data frames

qualR

Plots

Pacotes

- Pacotes são como as **extensões** no browser.
- Conjunto de funções específicas para tarefas específicas.

- Para instalar pacotes usamos a função
`install.packages("nome_do_biblioteca")`

Instalando Rmarkdown

```
install.packages("rmarkdown")
```

- Por exemplo, para ler arquivos `.xls` podemos instalar a biblioteca `readxls`

```
# Instalando readxl  
install.packages("readxl")
```

Do Excel para R

- Um jeito de ler arquivos `.xls` é abrir os arquivos em Excel ou Google Sheet e salvar como `.csv`.
- Depois ler a tabela usando a função `read.table()`
- As vezes vale a pena abrir no Excel ou Google Sheet e mudar o nome das colunas.
- Também podemos usar a função `read_excel()` do pacote `readxl`

- Vamos usar a base de dados de qualidade do ar da WHO

```
library(readxl)
who <- read_excel("../..//data/who_aap_2021_v9_11august2022.xlsx",
                  sheet = 2) # Nome o numero do sheet no arquivo
```

Base de dados da WHO

- Este é um exemplo de nomes de coluna *complicados*.

```
str(who)
```

```
## Classes 'tbl_df', 'tbl' and 'data.frame':    32191 obs. of  15 variables:
## $ WHO Region                               : chr  "Eastern Mediterranean"
## $ ISO3                                       : chr  "AFG" "ALB" "ALB" "ALB"
## $ WHO Country Name                         : chr  "Afghanistan" "Albania"
## $ City or Locality                         : chr  "Kabul" "Durrës" "Durrës"
## $ Measurement Year                        : num  2019 2015 2016 2015
## $ PM2.5 (µg/m3)                          : num  119.8 NA 14.3 NA NA
## $ PM10 (µg/m3)                           : num  NA 17.6 24.6 NA NA
## $ NO2 (µg/m3)                             : num  NA 26.6 24.8 24 26.3
## $ PM25 temporal coverage (%)              : num  18 NA NA NA NA NA
```

Subset data frames

Subset

- As vezes precisamos selecionar um sub-conjunto de dados do data frame.
- Um jeito simples é usar a função `subset()`

```
novo_df <- subset(df_original,  
                  subset = condição baseado nas filas,  
                  select = vetor com as colunas)
```

Subset dados da who para Brasil

- Vamos selecionar os dados do Brasil.

```
who_br <- subset(who,  
                 subset = `WHO Country Name` == "Brazil")
```

- Olha como o nome da coluna que tem espaços é escrita usando ' '.

Subset dados da who para Brasil

- Vamos selecionar os dados do Brasil.

```
# Examinando o novo data frame
```

```
nrow(who_br)
```

```
## [1] 479
```

```
head(unique(who_br$`City or Locality`))
```

```
## [1] "Americana" "Aracatuba" "Araraquara" "Araucaria" "Barra M"
```

```
## [6] "Bauru"
```

- Olha como o nome da coluna que tem espaços é escrita usando ' '.

Subset dados da WHO para Sao Paulo

```
who_sp <- subset(who,  
  subset = `City or Locality` == "Sao Paulo" ,  
  select = c("Measurement Year",  
    "PM2.5 (µg/m3)",  
    "PM10 (µg/m3)",  
    "NO2 (µg/m3)" ))
```

Subset dados da WHO para Sao Paulo

- Vamos arrumar um pouco o data frame

```
names(who_sp)
```

```
## [1] "Measurement Year" "PM2.5 (µg/m3)"    "PM10 (µg/m3)"     "NO2 (µg/m3)"
```

```
names(who_sp) <- c("year", "pm25", "pm10", "no2")
```

```
names(who_sp)
```

```
## [1] "year" "pm25" "pm10" "no2"
```


Anos acima do padrão da WHO

```
plot(who_sp$year, who_sp$no2, t = "l", lwd = 1.5,  
     xlab = "Anos", ylab = "NO2 (ug/m3)")  
abline(h = 40, lwd = 1.5, col = "red")  
legend("topright", col = "red", lwd = 1.5, legend = "NO2 WHO AQS")
```



- Que cidades ultrapassarm o Padrão de qualidade do ar de NO₂ no ano 2019?

qualR

- Pacote desenvolvido para baixar os dados da CETESB dentro do R.
- Gera dataset prontos e completos para análise:
 - Horários faltantes preenchidos com **NA**.
 - Coluna **date** tipo **POSIXct** para usar diretamente com **openair**.
- Precisa de ter cadastro na plataforma QUALAR da CETESB.
- Referencia qualR

- O jeito mais fácil é o seguinte:

```
install.packages('qualR',  
                 repos = c('https://ropensci.r-universe.dev',  
                           'https://cloud.r-project.org'))
```

Atenção

Para usar 'qualR' você precisa ter uma conta no sistema QUALAR da CETESB. Você precisa do **usuário** e da **senha**.

Códigos dos parâmetros e das estações

- Para saber os códigos das estações usamos `cetesb_aqs` na coluna `code`.

```
library(qualR)
head(cetesb_aqs, 4)
```

##	name	code	lat	lon	loc
## 1	Americana	290	-22.72425	-47.33955	Interior
## 2	Araçatuba	107	-21.18684	-50.43932	Interior
## 3	Araraquara	106	-21.78252	-48.18583	Interior
## 4	Bauru	108	-22.32661	-49.09276	Interior

Códigos dos parâmetros e das estações

- Para saber os códigos dos parâmetros `cetesb_param` na coluna `code`.

```
library(qualR)
tail(cetesb_param, 4)
```

##		name	units	code
## 17	TEMP (Temperatura do Ar)	°C	25	
## 18	TOL (Tolueno)	ug/m3	62	
## 19	UR (Umidade Relativa do Ar)	%	28	
## 20	VV (Velocidade do Vento)	m/s	24	

Baixar um poluente de uma estação

- Vamos baixar dados de ozônio da primeira semana de janeiro de 2024 na estação Pinheiros. Usamos a função `cetesb_retrieve_param()`.

```
pin_o3 <- cetesb_retrieve_param(  
  username = Sys.getenv("QUALAR_USER"), # Trocar pelo seu usuário  
  password = Sys.getenv("QUALAR_PASS"), # Trocar pela sua senha  
  parameters = 63, # de cetesb_param  
  aqs_code = 99, # de cetesb_aqs,  
  start_date = "01/01/2024", # Formato dd/mm/yyyy  
  end_date = "07/01/2024" # Formato dd/mm/yyyy  
)
```

Baixar um poluente de uma estação

- Também aceita o nome da estação (igual do que em `cetesb_aqs`) e o nome do parâmetro (igual do que em `cetesb_param`).

```
pin_o3 <- cetesb_retrieve_param(  
  username = Sys.getenv("QUALAR_USER"), # Trocar pelo seu usuário  
  password = Sys.getenv("QUALAR_PASS"), # Trocar pela sua senha  
  parameters = "O3", # de cetesb_param  
  aqs_code = "Pinheiros", # de cetesb_aqs,  
  start_date = "01/01/2024", # Formato dd/mm/yyyy  
  end_date = "07/01/2024" # Formato dd/mm/yyyy  
)
```

Baixar vários poluente de uma estação

- Também podemos baixar vários poluentes de uma estação. Só precisamos definir os poluentes para baixar em um **vetor**. Vamos baixar O₃, PM_{2.5}, e NO_x.

```
pols <- c("O3", "MP2.5", "NOx") # Olhar usando cetesb_aqs
pin_o3 <- cetesb_retrieve_param(
  username = Sys.getenv("QUALAR_USER"), # Trocar pelo seu usuário
  password = Sys.getenv("QUALAR_PASS"), # Trocar pela sua senha
  parameters = pols, # vetor com poluentes
  aqs_code = "Pinheiros", # de cetesb_aqs,
  start_date = "01/01/2024", # Formato dd/mm/yyyy
  end_date = "07/01/2024" # Formato dd/mm/yyyy
)
```

Baixar vários poluentes e meteorologia de uma estação

- Só precisamos definir os parâmetros para baixar em um vetor. Vamos baixar $PM_{2.5}$ e velocidade e direção do vento.

```
params <- c("MP2.5", "VV", "DV") # Olhar usando cetesb_aqs
pin_pm25 <- cetesb_retrieve_param(
  username = Sys.getenv("QUALAR_USER"), # Trocar pelo seu usuário
  password = Sys.getenv("QUALAR_PASS"), # Trocar pela sua senha
  parameters = params, # vetor com poluentes
  aqs_code = "Pinheiros", # de cetesb_aqs,
  start_date = "01/01/2024", # Formato dd/mm/yyyy
  end_date = "07/01/2024" # Formato dd/mm/yyyy
)
```

Baixar vários poluentes e meteorologia de uma estação

- Você não precisa colocar os argumentos das funções **mas precisa seguir a ordem dos argumentos.**

```
params <- c("MP2.5", "VV", "DV")
pin_pm25 <- cetesb_retrieve_param(
  Sys.getenv("QUALAR_USER"), # username
  Sys.getenv("QUALAR_PASS"), # password
  params, # parameters
  "Pinheiros", # aqs_code
  "01/01/2024", # start_date
  "07/01/2024" # end_date
)
```

Salvar dados em .csv

- Pode ser que você precisar usar outro software (e.g. PMF). Então você pode usar exportar os dados em .csv. Só adicionar o argumento `to_csv = TRUE`.

```
params <- c("MP2.5", "VV", "DV") # Olhar usando cetesb_aqs
pin_pm25 <- cetesb_retrieve_param(
  username = Sys.getenv("QUALAR_USER"), # Trocar pelo seu usuário
  password = Sys.getenv("QUALAR_PASS"), # Trocar pela sua senha
  parameters = params, # vetor com poluentes
  aqs_code = "Pinheiros", # de cetesb_aqs,
  start_date = "01/01/2024", # Formato dd/mm/yyyy
  end_date = "07/01/2024", # Formato dd/mm/yyyy
  to_csv = TRUE
)
```

Salvar dados em .csv

- O arquivo salvo tem o nome `Pinheiros_MP2.5_VV_DV_01-01-2024_07-01-2024.csv` e ficará na pasta de trabalho (conferir usando `getwd()`).

Um poluente várias estações

- As vezes você precisa de comparar valores de várias estações. Neste exemplo vamos baixar valores de NO_x da estação Ibirapuera e Pinheiros.

```
aqs <- c(99, 83) # de cetesb_aqs, Pinheiros é 99 e Ibirapuera 83
nox_pin_ibi <- lapply(
  aqs,
  cetesb_retrieve_param,
  username = Sys.getenv("QUALAR_USER"),
  password = Sys.getenv("QUALAR_PASS"),
  parameters = "NOx",
  start_date = "01/01/2024",
  end_date = "07/07/2024"
)
```


Um poluente várias estações

- O resultado de usar `lapply` é uma lista. Vamos a transformar em um `data.frame`.

```
nox_all <- do.call(rbind, nox_pin_ibi)
```

Um poluente várias estações

- Usando subset podemos separar os data frames.

```
nox_pin <- subset(nox_all, subset = aqs == "Pinheiros")  
nox_ibi <- subset(nox_all, subset = aqs == "Ibirapuera")
```

Um poluente várias estações

- Vamos comparar as estações

```
mean(nox_pin$nox, na.rm = TRUE)
```

```
## [1] 24.1
```

```
mean(nox_ibi$nox, na.rm = TRUE)
```

```
## [1] 13.50479
```

- Pinheiros tem maior concentração de NOX do que Ibirapuera. Por que?

Plots
